

Seminararbeit

Positionsbestimmung mit Hilfe von Inertialsensorik und Filteralgorithmen

Verfasser: Marcel Warcholik

Matrikelnummer: 833929

Betreuer: Prof. Dr. rer. nat. Horst Schäfer

Dipl. Ing. (FH) Moritz Zingsheim, M. Sc.

Aachen, 15.12.2011

Eidesstattliche Erklärung

Hiermit versichere ich, dass ich die Seminararbeit mit dem Thema

Positionsbestimmung mit Hilfe von

Inertialsensorik und Filteralgorithmen

selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe, alle Ausführungen, die anderen Schriften wörtlich oder sinngemäß entnommen wurden, kenntlich gemacht sind und die Arbeit in gleicher oder ähnlicher Fassung noch nicht Bestandteil einer Studien- oder Prüfungsleistung war.

Name: Marcel Warcholik

Aachen, den 15.12.2011



Unterschrift der Studentin / des Studenten

Inhaltsverzeichnis

1. Einleitung	1
2. Inertiale Navigationssysteme	2
2.1. Messprinzip	3
2.2. Messabweichungen.....	4
2.2.1. Hardwarebedingte Abweichungen	4
2.2.2. Anwendungsbedingte Abweichungen	6
3. Filteralgorithmen.....	8
3.1. Kalman-Filter	10
3.2. Partikel-Filter	17
3.3. Vergleich zwischen Kalman-Filter und Partikel-Filter	20
4. Stützungsmöglichkeiten	21
4.1. Global Positioning System	21
4.2. Bildgebende Verfahren	22
4.3. Redundante Inertialsensoren.....	23
5. Zusammenfassung und Ausblick.....	24
Literaturverzeichnis	25
Abbildungsverzeichnis	26
Formelverzeichnis.....	27
Abkürzungsverzeichnis	29
Einheitenverzeichnis.....	30
Anhang	31

1. Einleitung

Das Bestimmen von Position und Orientierung ist für viele Anwendungen eine Voraussetzung. Damit verbunden ist die Automatisierung von Prozessen und Arbeitsschritten, welche in der heutigen Zeit eine hohe Priorität erlangen. Die Technologie der Positionsbestimmung hat sich in den letzten 20 Jahren stets weiterentwickelt. Die benutzte Technik konnte deutlich miniaturisiert werden, sodass der Gebrauch in vielen Geräten, z.B. Smartphones, möglich ist. Das Bestimmen von Position und Orientierung ist aber auch für viele andere Bereiche, wie z.B. in der Fahrzeugnavigation notwendig. Die Navigation muss präzise und zuverlässig sein. Die Positionsbestimmung kann durch verschiedene Geräte, z.B. inertiale Navigationssysteme oder GPS, erfolgen. Mit der Verfügbarkeit von GPS-Empfängern hat sich die satellitengestützte Navigation als Standard-verfahren im Straßen-, Luft- und Schiffsverkehr durchgesetzt. Sobald der Empfang des GPS-Signals nicht sicher gewährleistet werden kann, sind die Grenzen der satellitengestützten Navigation erreicht. Insbesondere Anwendungen innerhalb von Gebäuden und Tunneln sind von dieser Einschränkung betroffen. Alternative Techniken wie inertiale Navigationssysteme müssen hier die Positionsbestimmung übernehmen. Inertiale Navigationssysteme bestehend aus Beschleunigung- und Drehratensensoren ermöglichen das Bestimmen von Position und Orientierung eines bewegten Objektes im Raum. Die ausgelesenen Werte der Inertialsensoren sind mit einer Messabweichung behaftet, die aus verschiedenen Störfaktoren entsteht. Die Funktionsweise von inertialen Navigationssystemen und verschiedene Arten von Messabweichungen werden in Kapitel 2 erläutert. Hohe Anforderungen an das System veranlassen dazu, Filteralgorithmen zu verwenden. Diese müssen je nach Anwendungsgebiet individuell angepasst und implementiert werden. Filteralgorithmen können die Messabweichungen häufig nur minimieren und nicht eliminieren, sodass eine weitere Stützungsmöglichkeit sinnvoll ist. Verschiedene Filteralgorithmen und deren Prinzip werden in Kapitel 3 vorgestellt. Unterschiedliche Arten zur Unterstützung von Filteralgorithmen sind möglich und in Kapitel 4 werden einige von ihnen vorgestellt.

2. Inertiale Navigationssysteme

Inertiale Navigationssysteme (INS), auch Trägheitsnavigationssysteme genannt, bestehen aus Beschleunigungssensoren und Drehratensensoren, die wie in Abbildung 1 dargestellt, orthogonal zueinander angeordnet sind und sich an den Einheitsvektoren orientieren. Diese Sensoren sind alle unabhängig voneinander, wodurch die Betrachtung der einzelnen Dimensionen möglich wird. Die Beschleunigungssensoren messen die translatorischen Freiheitsgrade, also die geradlinige Bewegung des ganzen Körpers in eine Richtung. Die rotatorischen Freiheitsgrade, die Bewegung auf einer kreisförmigen Bahn, sind die Winkelgeschwindigkeiten und werden durch die Drehratensensoren bestimmt. Die Integration der Drehrate über die Zeit ergibt den Kippwinkel. Eine Integration der Beschleunigung über die Zeit ergibt die Geschwindigkeit und eine erneute Integration über die Zeit die Positionsänderung, welche durch die Geschwindigkeit verursacht wurde. Insgesamt misst ein INS mindestens sechs Freiheitsgrade, nämlich Beschleunigung und Winkelgeschwindigkeit in den jeweiligen Raumrichtungen.




Abbildung 1: Anordnung der Sensoren in einem inertialen Navigationssystem
[4]

Im weiteren Verlauf dieser Arbeit werden nur mikroelektromechanische Systeme (MEMS) betrachtet. MEMS sind halbleiterbasierte Mikroprozessoren, die für viele Anwendungsgebiete, z.B. Airbags und Smartphones, entwickelt

und angepasst werden können. In einem INS sind das Drehraten- und Beschleunigungssensoren. Andere Messeinheiten für die Drehraten sind Faseroptische-Kreisel (FOG) und Ringlaser-Kreisel (RLG), die mithilfe von Lasern und Interferenzen die Drehbewegungen bestimmen. Diese werden zusätzlich mit Beschleunigungssensoren ausgestattet, um die Beschleunigung ermitteln zu können.

Die Einsatzgebiete von solchen Navigationssystemen sind hauptsächlich Luft- und Seefahrt. [1] Das Ziel solcher Navigationssysteme ist die automatisierte Navigation ohne zusätzliche Stützungsmöglichkeiten.

2.1. Messprinzip

Mithilfe der Inertialsensorik eines Trägheitsnavigationssystems kann die Position eines beobachteten Objektes referenzlos bestimmt werden. Mittels der Inertialsensoren werden Drehrate ω in $^\circ/s$ und Beschleunigung \vec{a} in m/s^2 bestimmt, was den sechs kinematischen Freiheitsgraden entspricht. Ist die Beschleunigung eines Objektes bekannt, so ergibt die Integration der Beschleunigung über die Zeit die Geschwindigkeit \vec{v} in m/s , wie in Formel 1 dargestellt.

$$\vec{v}(t) = \int_t \vec{a}(t) dt$$

Formel 1: Erste Herleitung aus dem zweiten Gesetz der Mechanik von Newton

In Formel 2 wird gezeigt, dass eine erneute Integration über die Zeit die Positionsänderung $\vec{s}(t)$ in m , die durch die Geschwindigkeit verursacht wurde, ergibt.

$$\vec{s}(t) = \int \int_t \vec{a}(t) d^2t$$

Formel 2: Zweite Herleitung aus dem zweiten Gesetz der Mechanik von Newton

Dies basiert auf dem 2. Gesetz der Mechanik von Newton, welches besagt, dass die zeitliche Änderung des Impulses gleich der wirkenden Kraft ist. Es könnte, bei gegebener Anfangsgeschwindigkeit und Ausgangspunkt, die daraus resultierende Positionsänderung, in Abhängigkeit von der Zeit, bestimmt werden.

Auch wenn die gegebenen Anfangswerte exakt sind, so muss davon ausgegangen werden, dass bei Messungen mit einem inertialen Navigationssystem immer Messabweichungen vorhanden sind. Diese Abweichungen werden im nachfolgenden Kapitel 2.2 näher erläutert.

2.2. Messabweichungen

Messabweichungen werden unterschieden in hardwarebedingte Abweichungen und anwendungsbedingte Abweichungen. Hardwarebedingte Abweichungen werden abhängig vom System erzeugt und können nicht beeinflusst werden. Anwendungsbedingte Abweichungen hingegen beeinflussen das System in Abhängigkeit von dem vorliegenden untertägigen Szenario. Für fast alle Messabweichungen gilt, dass die Aufsummierung der Messwerte minus den realen Wert nicht $\vec{0}$ ergibt:

$$\sum_n (\vec{x}_n - \vec{x}_{n,real}) \neq \vec{0}$$

Formel 3: Aufsummierung der Differenz von Messwerten und realen Werten

wobei n der Summenindex, \vec{x}_n die Messwerte und $\vec{x}_{n,real}$ die realen Werte sind.

2.2.1. Hardwarebedingte Abweichungen

Hardwarebedingte Abweichungen sind von Sensor zu Sensor unterschiedlich und sind stark von Bauart und Qualität des Sensors abhängig. Im Folgenden wird beschrieben, wie das thermische Rauschen und die Drift entstehen und in welcher Weise sie die Positionsbestimmung beeinflussen.

Thermisches Rauschen

Bei Stromdurchfluss durch nahezu alle Objekte tritt thermisches Rauschen auf. Durch die wärmebedingte Bewegung von Elektronen in der Leitung wird eine Rauschspannung und Rauschstrom erzeugt. Dies verursacht, am Beispiel eines XSENS MTI-G, eine Abweichung von 0.008 m/s^2 in der Beschleunigung und $0.286^\circ/\text{s}$ in der Drehrate. [Anhang 1] Diese Veränderung der Messdaten ist bei jedem Sensor unterschiedlich und hängt von Bauart und Qualität des Sensors ab. Diese Abweichungen sind nicht gering genug, um vernachlässigt werden zu können.

Drift

Die Dreh- und Beschleunigungssensoren sind mit einem zufälligen Nullpunktfehler, auch Bias genannt, belastet, welcher durch unterschiedliche Einflüsse wie Temperatur-, Luftdruck- und Magnetfeldänderungen vergrößert oder verkleinert wird [1]. Ein Nullpunktfehler entsteht, wenn ein Wert, bei ruhendem Navigationsgerät, der gleich null sein sollte, ungleich null ist. In Abbildung 2 wird dies für die Beschleunigung gezeigt.




Abbildung 2: Einfluss der Abweichungen auf die Beschleunigung

Eine Integration der Beschleunigung über die Zeit ergibt die Geschwindigkeit, wobei der Messfehler aber auch integriert wird und linear ansteigt, wie in Abbildung 3 dargestellt. Dies wird als Drift bezeichnet. Die Positionsänderung

im Raum, die mit Hilfe der zweifachen Integration der Beschleunigung über die Zeit bestimmt wird, ist mit einem Positionsfehler belastet, der quadratisch wächst. [2] Diese Abweichung wird in Abbildung 4 verdeutlicht.




Abbildung 3: Drift mit linearer Abweichung

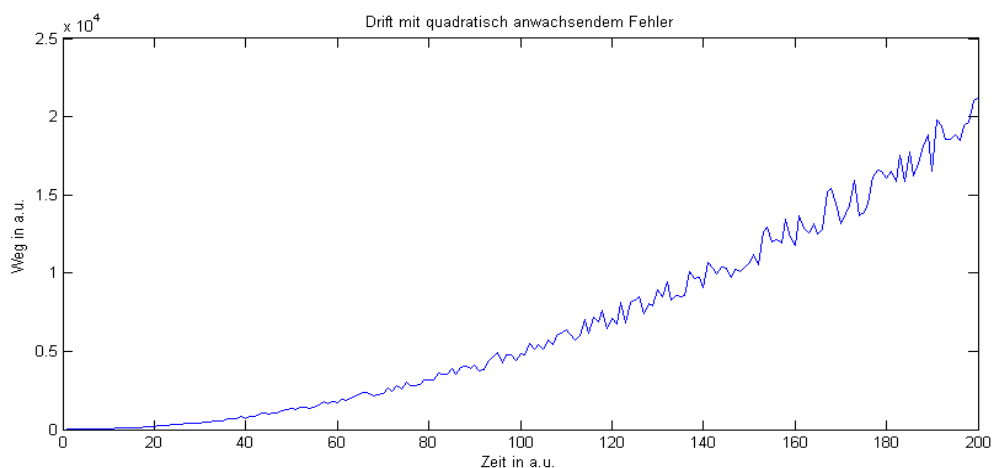


Abbildung 4: Drift mit quadratischer Abweichung

Dieser Effekt wird durch die Drehung der Erde um die eigene Achse, ca. $15^\circ/h$ und die Drehung um die Sonne, ca. $0,04^\circ/h$, verstärkt und führt deshalb zu größeren Messabweichungen, wenn der Sensor sich in seinem Bezugssystem in Ruhe befindet. [1]

2.2.2. Anwendungsbedingte Abweichungen

Die folgenden anwendungsbedingten Abweichungen treten auf, weil ein Trägheitsnavigationssystem auf einer untertägigen Maschine angebracht wird.

Jene Maschine bewegt sich auf einer unebenen und rauen Fläche und ist verschiedenen Bedingungen ausgesetzt.

Schockbelastungen

Durch das gegebene Szenario sind die Sensoren mehreren Belastungen ausgesetzt. Verschiedene Materialien können Stöße auf das Navigationssystem und dessen Nähe ausüben. Die Drehraten- und Beschleunigungssensoren nehmen starke Messabweichungen auf, welche Bewegungen und Drehungen entsprechen, die nicht gemacht wurden. Diese Abweichungen dürfen nicht vernachlässigt werden und müssen durch andere Systeme, wie z.B. Dämpfung der Sensoren, korrigiert werden.

Vibrationen

Vibrationen sind Scheinbewegungen des Sensors, welche durch verschiedene Faktoren in einem untätigen Szenario verursacht werden. Sowohl der Elektromotor, als auch die raue unebene Fläche, auf welcher sich die Maschine bewegt, lösen Vibrationen aus.

Vibrationen sind periodische und fühlbare Schwingungen, die meist eine niedrige Amplitude haben. Sie treten an elastischen oder elastisch zusammengesetzten Körpern auf und bewegen den Körper aus seiner Ruhelage.

[3]

Im Idealfall ist die Summe der Abweichungen, die durch die Vibration verursacht wurden, gleich $\vec{0}$. Durch eine endliche Messrate des Sensors kann diese Summe aber auch von $\vec{0}$ abweichen.

3. Filteralgorithmen

Um die vorher erwähnten Messabweichungen zu verringern oder im Optimalfall zu eliminieren, werden Filteralgorithmen benötigt. Der Einsatz solcher Algorithmen ist sinnvoll, aber meist nicht einfach zu realisieren. Die Probleme der realen Welt müssen erst analysiert und in mathematische Formeln übertragen werden, bevor eine Optimierung der Messwerte durch eine Schätzung durchgeführt werden kann. Eine typische Anwendung und Ablauf einer Messung mit Filter für Lokalisierungsprobleme ist in Abbildung 5 dargestellt.

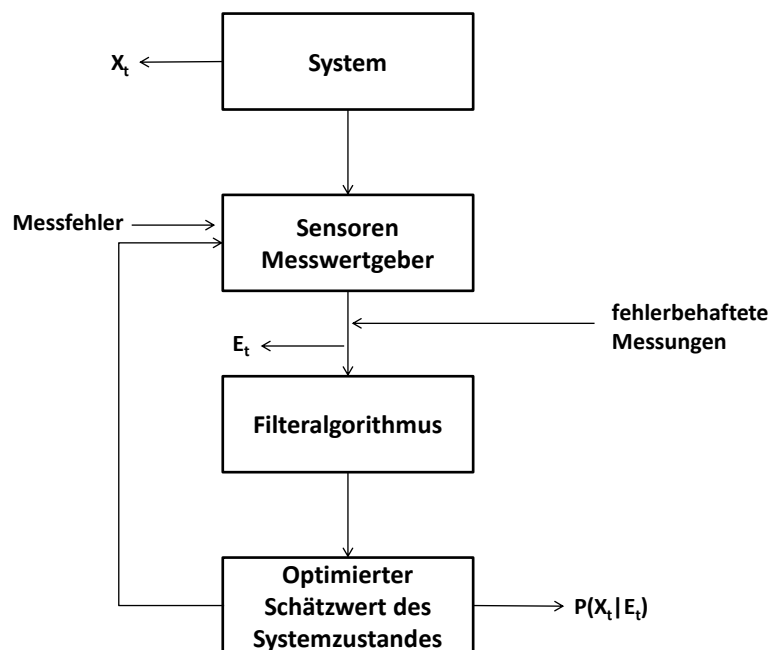


Abbildung 5: Typische Anwendung eines Filteralgorithmus

Die bekannten Eingangsgrößen für einen Filter sind die Beobachtungen, die das Trägheitsnavigationssystem wahrnehmen kann. Diese Informationen werden aus den verschiedenen Sensoren des Systems entnommen und werden als Evidenzen bezeichnet. Die Evidenzen sind von der Zeit abhängig und werden in verschiedenen Variablen gespeichert. Die Menge der beobachtbaren Evidenzvariablen zur Zeit t wird als E_t dargestellt. Die Evidenz zur Zeit t besteht aus einer Menge von Variablen e_t , sodass $E_t = e_t$ gilt. Die realen Werte

$X_t = x_t$ sind die nicht beobachtbaren Zustandsvariablen, welche auch von der Zeit abhängig sind. Es wird angenommen, dass die realen Werte nur von dem vorherigen Wert und nicht von weiter zurückliegenden Werten abhängig sind, wie in Formel 4 gezeigt wird. Diese beschreibt, wie sich der Zustand über die Zeit entwickelt.

$$P(X_t|X_{0:t-1}) = P(X_t|X_{t-1})$$

Formel 4: Übergangsmodell für Prozesse erster Stufe

Wie die Zustandsvariablen müssen auch die Evidenzvariablen beschränkt werden. In Formel 5 wird angenommen, dass die Evidenzvariablen zur Zeit t weder von vergangenen Zuständen, noch von vorherigen Evidenzvariablen abhängig sind, sondern nur von dem aktuellen Zustand X_t . Diese beschreibt ein Sensormodell und wie der aktuelle Zustand die Evidenzen beeinflusst. [6]

$$P(E_t|X_{0:t}, E_{0:t-1}) = P(E_t|X_t)$$

Formel 5: Sensormodell für Prozesse erster Stufe

Um die Funktionsweise eines Filters zu verdeutlichen kann das folgende Beispiel betrachtet werden, welches in Abbildung 6 dargestellt ist. Eine Person bewegt sich von Position A nach Position D. Aufgrund der Unsicherheit verändert sich die Wahrscheinlichkeitsdichte $f(x)$ und damit die erwartete Position der Person. Je länger sich die Person bewegt, desto ungenauer wird die angenommene Position. Nur durch eine Stützung der Messwerte, hier zwischen Position C und D, kann die Genauigkeit über die Position verbessert werden. In diesem Fall könnte eine Stützung die Beobachtung eines Hauses sein oder die Information seiner aktuellen Koordinaten.




Abbildung 6: Wahrscheinlichkeitsdichte der Position einer bewegenden Person

Im Folgenden werden der Kalman-Filter und der Partikel-Filter vorgestellt, zwei der meistverwendeten Filter.

3.1. Kalman-Filter

Der Kalman-Filter, benannt nach seinem Entwickler Rudolf E. Kálmán, wurde 1960 veröffentlicht. Ein ähnliches Verfahren wurde bereits 1958 von Peter Swerling publiziert. Es existieren bereits sehr viele unterschiedliche Arten des Kalman-Filters für verschiedene Anwendungsgebiete. Der Kalman-Filter kann für fast alle unterschiedlichen, linearen Szenarien benutzt werden, wobei die mathematische Struktur des Systems und die Messabweichungen bekannt sein müssen. [7]

In Abbildung 6 wurde verdeutlicht, wie sich die Wahrscheinlichkeitsdichte nach einer Bewegung verändert. Diese Wahrscheinlichkeitsdichten werden bei dem Kalman-Filter als Wahrscheinlichkeitsdichten der Gauß-Verteilung, auch Normalverteilung genannt, angenommen. Das Prinzip des Kalman-Filters beruht auf dem Prinzip der Normalverteilung. In der Darstellung für lineare stochastische Zustände wird der Kalman-Filter als Bayes'scher Minimum-Varianz-Schätzer bezeichnet. Seien in einem Szenario die gemessenen Werte und ihre Messabweichungen normalverteilt, als auch die Varianzen σ^2 der Messabweichungen bekannt, so ist die Filterung mithilfe des Kalman-Filters

optimal (Beweis: siehe [8]). Im weiteren Verlauf wird der Kalman-Filter nur noch auf lineare, zeitinvariante und instationäre Prozesse bezogen.

Um ein Szenario zu modellieren wird eine multivariate Gaußsche Verteilung spezifiziert. Für d Variablen wird eine d Elemente große Mittelwert- μ - und eine $d \times d$ -Kovarianzmatrix Σ benötigt. Eine Gaußsche Verteilung für die Vorhersage ist gegeben, wenn die aktuelle Verteilung $P(X_t|e_{1:t})$ eine Gaußsche Verteilung ist und das Übergangsmodell $P(X_{t+1}|x_t)$ eine lineare Gaußsche Verteilung ist. Die vorhergesagte Verteilung kann dann, wie in Formel 6, dargestellt werden.

$$P(X_{t+1}|e_{1:t}) = \int_{x_t} P(X_{t+1}|x_t) \cdot P(x_t|e_{1:t}) dx_t$$

Formel 6: Einstufige vorhergesagte Verteilung

Diese einstufige Vorhersage kann mithilfe einer Konditionierung auf die neuen Evidenzen aktualisiert werden. Dabei ist α die Normalisierungskonstante, die dafür sorgt, dass die Fläche unter der Dichtefunktion 1 ergibt. Dieses α verändert sich im Laufe der Aktualisierungen durch die durchgeführten Multiplikationen. Wenn die vorhergesagte Verteilung (vergleiche Formel 6) eine Gaußsche Verteilung ist und das Sensormodell eine linear Gaußsche Verteilung, so ist die aktualisierte Verteilung nach Konditionierung ebenfalls eine Gaußsche Verteilung. Diese aktualisierte Verteilung ist in Formel 7 dargestellt.

$$P(X_{t+1}|e_{1:t+1}) = \alpha \cdot P(e_{t+1}|X_{t+1}) \cdot P(X_{t+1}|e_{1:t})$$

Formel 7: Aktualisierung der Verteilung

Die Kalman-Filterung benutzt sowohl eine Mittelwert- μ_t -Matrix, als auch eine Kovarianzmatrix Σ_t , welche zusammen als Vorwärtsnachricht $f_{1:t}$ bezeichnet wird. Daraus wird die Vorwärtsnachricht $f_{1:t+1}$ erzeugt, die wiederum durch eine Mittelwert- μ_{t+1} - und eine Kovarianzmatrix Σ_{t+1} spezifiziert wird. Bei einer, als Ausgangsposition angenommenen, unbedingten Gaußschen Verteilung (vergleiche Formel 8) erzeugt die Filterung mit einem linearen Gaußschen Modell eine Gaußsche Zustandsverteilung für die gesamte Zeit. [6]

$$f_{1:0} = P(X_0) = N(\mu_0, \Sigma_0)$$

Formel 8: Beispiel einer unbedingten Gaußschen Verteilung

Die Vorwärtsnachricht für den Kalman-Filter soll eine Gaußsche Verteilung auf eine neue Gaußsche Verteilung abbilden. Dafür müssen aus den alten Mittelwert- und Kovarianzmatrizen die neuen Mittelwert- und Kovarianzmatrizen bestimmt werden.

Im Folgenden wird die Vorgehensweise und Wirkung des Kalman-Filters an einem eindimensionalen Beispiel demonstriert. Die stetige Zustandsvariable X_t beschreibt einen zufälligen Weg und Z_t die messbare Beobachtung mit einer Messabweichung. Die unbedingte Gaußsche Verteilung mit der Varianz σ_0^2 ist in Formel 9 dargestellt.

$$P(X_0) = \alpha \cdot e^{-\frac{1}{2} \cdot \left(\frac{(x_0 - \mu_0)^2}{\sigma_0^2} \right)}$$

Formel 9: Eindimensionale unbedingte Anfangsverteilung

In Formel 10 wird dem aktuellen Zustand vom Übergangsmodell ein Gaußsches Rauschen mit der Varianz σ_x^2 hinzugefügt.

$$P(x_{t+1}|x_t) = \alpha \cdot e^{-\frac{1}{2} \cdot \left(\frac{(x_{t+1} - x_t)^2}{\sigma_x^2} \right)}$$

Formel 10: Eindimensionales Übergangsmodell mit Gaußschem Rauschen

Das Sensormodell erhält ebenfalls ein Gaußsches Rauschen mit der Varianz σ_z^2 . Dies wird in Formel 11 verdeutlicht.

$$P(z_t|x_t) = \alpha \cdot e^{-\frac{1}{2} \cdot \left(\frac{(z_t - x_t)^2}{\sigma_z^2} \right)}$$

Formel 11: Eindimensionales Sensormodell mit Gaußschem Rauschen

Mithilfe der unbedingten Anfangsverteilung $P(X_0)$ kann eine einstufige vorhergesagte Verteilung $P(x_1)$ bestimmt werden. Dies wird in Formel 12 durch Verwendung von Formel 6 gezeigt.

$$\begin{aligned}
P(x_1) &= \int_{-\infty}^{\infty} P(x_1|x_0) \cdot P(x_0) dx_0 \\
&= \alpha \cdot \int_{-\infty}^{\infty} e^{-\frac{1}{2} \cdot \left(\frac{(x_1 - x_0)^2}{\sigma_x^2} \right)} \cdot e^{-\frac{1}{2} \cdot \left(\frac{(x_0 - \mu_0)^2}{\sigma_0^2} \right)} dx_0 \\
&= \alpha \cdot \int_{-\infty}^{\infty} e^{-\frac{1}{2} \cdot \left(\frac{\sigma_0^2 \cdot (x_1 - x_0)^2 + \sigma_x^2 \cdot (x_0 - \mu_0)^2}{\sigma_0^2 \cdot \sigma_x^2} \right)} dx_0
\end{aligned}$$

Formel 12: Eindimensionale einstufige vorhergesagte Verteilung

Durch geschickte Umformung kann ein Teil aus dem Integral herausgezogen werden, welches dann 1 ergibt, weil über den gesamten Bereich einer Gaußschen Verteilung integriert wird. Der Restterm muss quadratisch in x_1 sein und wird in Formel 13 dargestellt.

$$P(x_1) = \alpha \cdot e^{-\frac{1}{2} \cdot \left(\frac{(x_1 - \mu_0)^2}{\sigma_0^2 + \sigma_x^2} \right)}$$

Formel 13: Vereinfachte eindimensionale einstufige vorhergesagte Verteilung

Die neue vorhergesagte Verteilung ist eine Gaußsche Verteilung mit dem gleichen Mittelwert μ_0 aus der Anfangsverteilung. Die Varianz besteht aus der Summe der Anfangsvarianz σ_0^2 und der Übergangsvarianz σ_x^2 . Um die Aktualisierung abzuschließen, muss die vorhergesagte Verteilung, mithilfe von Formel 7, auf die Evidenzen konditioniert werden. Daraus ergibt sich die aktualisierte Verteilung, die in Formel 14 gezeigt wird.

$$\begin{aligned}
P(x_1|z_1) &= \alpha \cdot P(z_1|x_1) \cdot P(x_1) \\
&= \alpha \cdot e^{-\frac{1}{2} \cdot \left(\frac{(z_1 - x_1)^2}{\sigma_z^2} \right)} \cdot e^{-\frac{1}{2} \cdot \left(\frac{(x_1 - \mu_0)^2}{\sigma_0^2 + \sigma_x^2} \right)}
\end{aligned}$$

Formel 14: Aktualisierte eindimensionale einstufige vorhergesagte Verteilung

Diese Verteilung kann auch weiter vereinfacht werden, damit die Gleichungen für die Bestimmung des neuen Mittelwertes und der neuen Varianz abgelesen werden können. Durch Kombination der Exponenten und weiteres

Vereinfachen kann die aktualisierte Verteilung, wie in Formel 15, dargestellt werden.

$$P(x_1|z_1) = \alpha \cdot e^{-\frac{1}{2} \cdot \left(\frac{(x_1 - \frac{(\sigma_0^2 + \sigma_x^2) \cdot z_1 + \sigma_z^2 \cdot \mu_0}{\sigma_0^2 + \sigma_x^2 + \sigma_z^2})^2}{\frac{(\sigma_0^2 + \sigma_x^2) \cdot \sigma_z^2}{(\sigma_0^2 + \sigma_x^2 + \sigma_z^2)}} \right)}$$

Formel 15: Vereinfachte aktualisierte eindimensionale einstufige vorhergesagte Verteilung

Dieser Aktualisierungszyklus erzeugt eine neue Gaußsche Verteilung für die Zustandsvariable. Aus Formel 15 können die Gleichungen für die Aktualisierung des Mittelwertes abgelesen werden. Dies wird in Formel 16 verdeutlicht.

$$\mu_{t+1} = \frac{(\sigma_t^2 + \sigma_x^2) \cdot z_{t+1} + \sigma_z^2 \cdot \mu_t}{\sigma_t^2 + \sigma_x^2 + \sigma_z^2}$$

Formel 16: Berechnung des neuen Mittelwertes

Der neue Mittelwert hängt von dem alten Mittelwert, der Evidenzvariablen und den Varianzen ab. Die neue Varianz hingegen hängt nur von den alten Varianzen ab und nicht von der Evidenzvariablen. Die Berechnung der neuen Varianz wird in Formel 17 dargestellt.

$$\sigma_{t+1}^2 = \frac{(\sigma_t^2 + \sigma_x^2) \cdot \sigma_z^2}{\sigma_t^2 + \sigma_x^2 + \sigma_z^2}$$

Formel 17: Berechnung der neuen Varianz

Die Gaußsche Verteilung, der Mittelwert und die Varianz müssen in jedem Schritt aktualisiert werden, um die Zustandsvariable zu bestimmen. Dies gilt nicht nur für den eindimensionalen Fall, sondern auch für den allgemeinen Fall. Für den allgemeinen Fall wird aber eine multivariate Gaußsche Verteilung benötigt, die in Formel 18 dargestellt wird. Bei d Variablen ist μ eine d Elemente große Mittelwertmatrix und Σ eine $d \times d$ große Kovarianzmatrix.

$$N(\mu, \Sigma)(x) = \alpha \cdot e^{-\frac{1}{2} \cdot ((x - \mu)^T \cdot \Sigma^{-1} \cdot (x - \mu))}$$

Formel 18: Allgemeine multivariate Gaußsche Verteilung

Auch im allgemeinen Fall wird sowohl dem Übergangsmodell (siehe Formel 19), als auch dem Sensormodell (vergleiche Formel 20) ein Gaußsches Rauschen mit den Kovarianzmatrizen Σ_x bzw. Σ_z hinzugefügt.

$$P(x_{t+1}|x_t) = N(F \cdot x_t, \Sigma_x)(x_{t+1})$$

Formel 19: Allgemeines Übergangsmodell mit Gaußschem Rauschen

$$P(z_t|x_t) = N(H \cdot x_t, \Sigma_z)(z_t)$$

Formel 20: Allgemeines Sensormodell mit Gaußschem Rauschen

Das allgemeine Übergangsmodell wird durch die Matrix F , dem linearen Übergangsmodell, und der Übergangsrauschkovarianzmatrix Σ_x beschrieben. Für das allgemeine Sensormodell werden entsprechende Matrizen benötigt. Die Matrizen H und Σ_z beschreiben das Sensormodell. Wie im eindimensionalen Beispiel können die Aktualisierungen für die Mittelwerte und Kovarianzen daraus abgeleitet werden. Die Aktualisierung für die Mittelwertmatrix μ_{t+1} ist in Formel 21 dargestellt.

$$\mu_{t+1} = F \cdot \mu_t + K_{t+1} \cdot (z_{t+1} - H \cdot F \cdot \mu_t)$$

Formel 21: Allgemeine Aktualisierung der Mittelwertmatrix

Die Berechnung der aktualisierten Kovarianzmatrix wird in Formel 22 gezeigt, wobei I die Einheitsmatrix darstellt.

$$\Sigma_{t+1} = (I - K_{t+1}) \cdot (F \cdot \Sigma_t \cdot F^T + \Sigma_x)$$

Formel 22: Allgemeine Aktualisierung der Kovarianzmatrix

Die Matrix K_{t+1} stellt die Kalman-Gewinnmatrix dar. Diese gibt an, wie die Beobachtung im Hinblick auf die vorhergesagte Verteilung berücksichtigt

werden muss. Die Berechnung der Kalman-Gewinnmatrix wird in Formel 23 verdeutlicht.

$$K_{t+1} = (F \cdot \Sigma_t \cdot F^T + \Sigma_x) \cdot H^t \cdot (H \cdot (F \cdot \Sigma_t \cdot F^T + \Sigma_x) \cdot H^T + \Sigma_z)^{-1}$$

Formel 23: Definition der Kalman-Gewinnmatrix

Anhand dieser Aktualisierungen kann die Positionsschätzung mittels der Beobachtungen verbessert werden. Die geschätzte Position ist das Maximum der Verteilung $P(x_1|z_1)$. Bei Gaußschen Verteilungen ist das Maximum der Wahrscheinlichkeitsdichte der Erwartungswert der Verteilung. In Abbildung 7 werden die verschiedenen Verteilungen eines eindimensionalen Beispiels gezeigt.




Abbildung 7: Gaußsche Verteilungen eines eindimensionalen Beispiels
[6]

Die Verteilung $P(x_0)$ ist die Gaußsche Anfangsverteilung. Die vorhergesagte Normalverteilung wird durch $P(x_1)$ dargestellt, welche durch die Beobachtung z_1 aktualisiert wird. Durch die Aktualisierung ergibt sich eine neue aktualisierte Gaußsche Verteilung $P(x_1|z_1)$, dessen Erwartungswert die optimierte Positionsschätzung für den Zustand ist. [6]

3.2. Partikel-Filter

Der Partikel-Filter basiert auf den sequenziellen Monte-Carlo-Methoden. Diese Methoden sollen einen Zustand schätzen, weil dieser nicht beobachtbar, sondern nur durch fehlerbehaftete Messungen zugänglich ist. Im Gegensatz zum Kalman-Filter muss der Zustand nicht linear sein und die Störeinflüsse können als nicht normalverteilt angenommen werden.

Die geschätzte Position ist bei dem Partikel-Filter nicht der Erwartungswert der Normalverteilung, sondern eine endliche Anzahl von möglichen Punkten im Raum. Die Punkte werden Partikel genannt und enthalten neben ihren eigenen Positionsinformationen auch eine Gewichtung. Die Summe aller Gewichtungen ω_i muss immer 1 ergeben (siehe Formel 24).

$$\sum_i (\omega_i) = 1$$

Formel 24: Aufsummierung aller Gewichtungen

Die Funktionsweise ist ähnlich wie bei dem Kalman-Filter. Es gibt ein Übergangsmodell, was die Bewegung beschreibt und das Sensormodell, welches die Gewichtung verändert. Beide Modelle sind wieder mit einem Fehler behaftet, welcher aber nicht als normalverteilt angenommen werden muss. Der Fehler kann durch eine beliebige Verteilung mit konstanten Parametern dargestellt werden. In Abbildung 8 wird der Ablauf eines Partikel-Filters gezeigt.

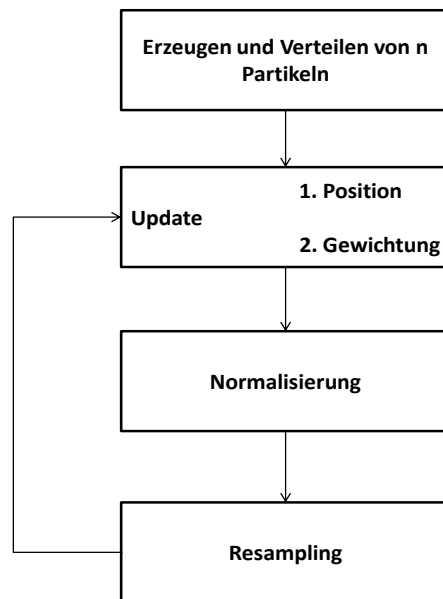


Abbildung 8: Ablauf eines Partikel-Filters

Jeder der n Partikel wird erzeugt und bekommt eine bestimmte Position, die durch eine Verteilung festgelegt ist. Je nach vorhandenen Informationen kann eine gute Verteilung spezifiziert werden. Sind keine Informationen vorhanden, so sollte eine Gaußsche Verteilung benutzt werden. Anfangs ist die Gewichtung jedes Partikels gleich, sodass Formel 25 gilt.

$$\omega_i = \frac{1}{n} \quad \forall 1 \leq i \leq n$$

Formel 25: Anfangswerte der Gewichtungen jedes Partikels

Nach dieser Anfangsbelegung muss die Position und die Gewichtung jedes Partikels aktualisiert werden. Diese beiden Schritte werden zusammen als Update bezeichnet. Die Position wird mithilfe des Übergangsmodells aktualisiert. Anhand der Evidenzen, welche zusätzlich noch gestützt werden können, werden die neuen Gewichtungen ω'_i durch das Sensormodell berechnet. Da die Summe der neuen Gewichtungen aber nicht 1 ergibt, muss jede Gewichtung mithilfe von Formel 26 normalisiert werden.

$$\omega_i'' = \frac{\omega_i'}{\sum_i \omega_i'} \quad \forall 1 \leq i \leq n$$

Formel 26: Normalisierung der Gewichtungen

Nach der Normalisierung kommt das Resampling, wo n neue Partikel erzeugt werden. Die Position und Gewichtung der neuen Partikel wird über die alten Partikel mittels Ziehen mit Zurücklegen bestimmt. Je größer die Gewichtung des Partikels ist, desto höher ist die Wahrscheinlichkeit, dass dieser gezogen wird. Nach mehreren Zyklen sammeln sich viele Partikel an einer Position. Im Updateschritt bekommt jeder Partikel wieder einen Fehler in seiner Position, wodurch sich eine große Masse an Partikeln in einem Gebiet aufhalten.

Die Veränderung der Position der Partikel wird in Abbildung 9 verdeutlicht.

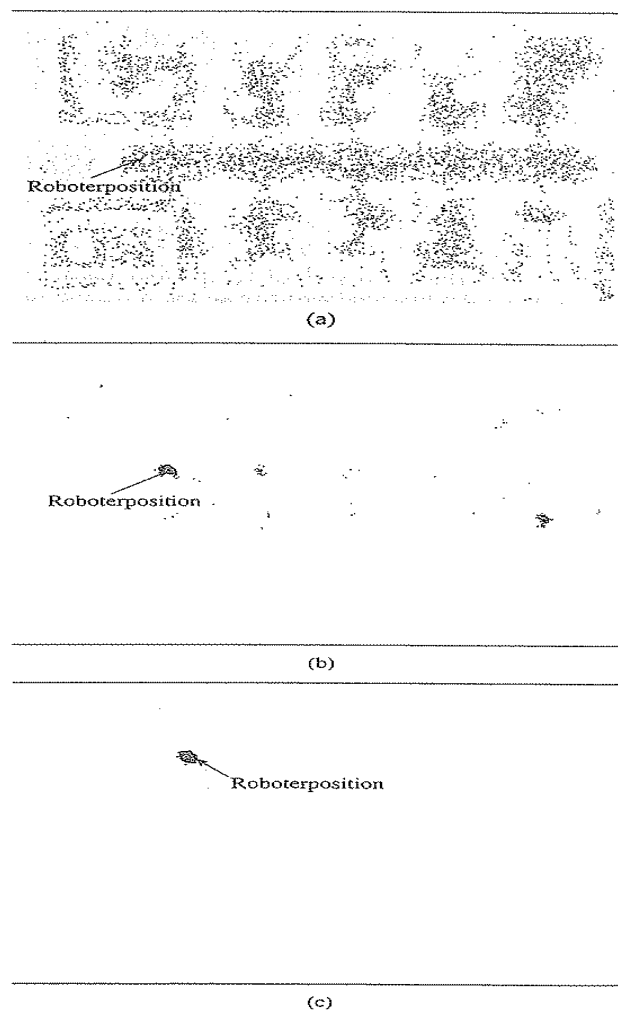


Abbildung 9: Verteilung der Partikel für die Roboterposition
[6]

Gesucht ist die Position eines sich bewegenden Roboters, welche immer markiert ist. In (a) ist die Anfangsverteilung der Partikel und die Anfangsposition der Roboters angegeben. In (b) wird die Verteilung der Partikel nach mehreren Zyklen gezeigt. Dort befinden sich schon viele Partikel in der Nähe der Roboterposition. Im letzten Bild (c) sind bereits alle Partikel in der Nähe des Roboters und geben eine gute Schätzung für die Position des Roboters.

Der Partikel-Filter konvergiert schnell gegen eine oder mehrere Positionen. Die Anzahl der Positionen hängt von den verfügbaren Informationen ab, womit die Gewichtungen aktualisiert wurden. Die Genauigkeit und die Konvergenzgeschwindigkeit werden erhöht, je mehr Partikel benutzt werden.

3.3. Vergleich zwischen Kalman-Filter und Partikel-Filter

Im Vergleich bieten beide Filter Vor- und Nachteile. Die Entscheidung, welcher Filter benutzt werden sollte, hängt stark vom Einsatzgebiet ab. Beide Filter konvergieren schnell gegen den richtigen Wert mit kleinen Abweichungen. Der Fehler lässt sich bei dem Partikel-Filter beliebig modellieren, wobei dieser bei dem Kalman-Filter immer als normalverteilt angenommen wird. Optimal ist der Kalman-Filter nur dann, wenn der Fehler auch normalverteilt ist. Desweiteren können mit dem Kalman-Filter nur lineare Probleme betrachtet werden. Der Partikel-Filter ist nicht auf die Linearität der Zustände angewiesen. Ein weiterer Vorteil, den der Partikel-Filter liefert, ist seine Skalierbarkeit. Die Anzahl der Partikel kann individuell bestimmt und die Genauigkeit, als auch die Konvergenzgeschwindigkeit beeinflusst werden. Außerdem lässt sich der Partikel-Filter aufgrund seiner Struktur gut parallelisieren.

4. Stützungsmöglichkeiten

In diesem Kapitel werden verschiedene Möglichkeiten vorgestellt, mit denen die Genauigkeit eines Trägheitsnavigationssystems verbessert werden kann. Dabei werden die Funktionsweisen und Einsatzmöglichkeiten von Global Position System, bildgebenden Verfahren und redundanten Inertialsensoren vorgestellt. Diese Stützungsmöglichkeiten liefern Daten, die für den verwendeten Filteralgorithmus benutzt werden können. Durch diese Daten kann die Schätzung eines Filters verbessert werden, was eine verbesserte Positionsbestimmung zur Folge hat.

4.1. Global Positioning System

Global Positioning System (GPS) ist ein Positionierungssystem, welches auf Satellitennavigation basiert und die aktuelle Position sowie Zeit bestimmen kann. Für die Bestimmung der Position wird der Empfang von mindestens drei Satelliten benötigt. Die Zeit kann mithilfe eines vierten Satellitensignals angegeben werden. Die Positionsbestimmung muss unterschieden werden in den Standard Positioning Service (SPS) und den Precise Positioning Service (PPS). SPS ist frei verfügbar und hat in 95% der Messungen eine Genauigkeit von ca. 7,8 Metern. PPS ist nur für das Militär zugänglich und hat eine Genauigkeit von wenigen Zentimetern. [5]

Wird ein GPS-Empfänger mit einem Trägheitsnavigationssystem gekoppelt, so kann die die Position des Objekts genauer bestimmt werden. Die Daten, die ein GPS-Empfänger misst, können auch als Ausgangsposition des Objekts betrachtet werden. Mittels der Beschleunigungs- und Drehratensensoren eines INS können die GPS-Daten laufend verbessert werden.

GPS ist wegen der Abhängigkeit von Satellitensignalen nur beschränkt einsetzbar und eignet sich z.B. nicht für Indoor-Navigationen oder untertägige Navigation, weshalb es nicht weiter betrachtet wird. Die Hauptanwendungsbereiche von GPS sind die Fahrzeugnavigation und die Luftfahrt.

4.2. Bildgebende Verfahren

Bildgebende Verfahren dienen der Erzeugung eines Bildes von dem Raum, in dem sich das Messgerät befindet. Je nach Wellenlänge bzw. Frequenz der elektromagnetischen Strahlung können unterschiedliche Bilder erzeugt werden. Anhand von erkennbaren Anhaltspunkten auf diesen Bildern kann die Positionsbestimmung verbessert werden. Wird der Einzugswinkel auf verschiedenen Bildern von verschiedenen Positionen auf das gleiche Bezugsobjekt betrachtet, so kann die Entfernung zu diesem Objekt bestimmt werden und die Inertialsensorik eines Navigationssystem unterstützen.

In diesem Abschnitt wird die Generierung von Bildern im menschlich sichtbaren Bereich, Infrarotbildern, sowie deren Vor- und Nachteile und Einsatzmöglichkeiten behandelt.

Konventionelle Bilderzeugung

Für die konventionelle Bilderzeugung werden Kameras benötigt. Diese Kameras sind weit verbreitet, kostengünstig und bieten eine nahezu beliebig hohe Auflösung. Die erzeugten Bilder können in schwarz/weiß sein oder Farbinformationen liefern, wie ein menschliches Auge diese wahrnehmen würde. Die Nachteile solcher Kameras sind die Empfindlichkeiten gegenüber Schmutz, Wasser, Staub und Nebel. Außerdem muss eine Lichtquelle vorhanden sein, um verwertbare Informationen geliefert zu bekommen. Aufgrund dieser Gegebenheiten ist ein Einsatz solcher Kameras für untertägige Bilderzeugung nur bedingt geeignet.

Bilderzeugung mit Infrarotstrahlung

Mithilfe von Infrarotkameras können Bilder erzeugt werden, in denen die Temperatur in der Umgebung visualisiert wird (ugs. Wärmebild). Infrarotstrahlung ist im Gegensatz zu Licht unempfindlicher gegenüber Umgebungsstörquellen und braucht keine Lichtquelle für die Bilderzeugung. Die Positionsbestimmung mithilfe von Infrarotstrahlung ist aber kaum möglich, da die Infrarotkameras eine geringe Auflösung haben und die dynamische,

untertägige Umgebung, ohne vorherige Bearbeitung der Bilder, kaum spezifische, erkennbare Anhaltspunkte zulässt.

4.3. Redundante Inertialsensoren

Mehrere Sensoren können zusammen verwendet werden, um die Schätzung des Filteralgorithmus zu verbessern. Dabei muss die Redundanz unterschieden werden in komplementäre und in parallele Redundanz. Komplementäre Redundanz von Sensoren ist die Verwendung mehrerer unterschiedlicher Sensoren, z.B. Beschleunigungs- und Drehratensensoren mit zusätzlichen Magnetfeldsensoren, und wird hauptsächlich im Bereich der Orientierungssensorik verwendet. Das Benutzen mehrerer gleicher Sensoren ist dagegen die parallele Redundanz und wird meistens in der Positionsbestimmung verwendet. Diese Sensoren werden unterschiedlich im System angeordnet, um unabhängige Messergebnisse zu erhalten. Durch die redundante Verwendung von Sensoren lässt sich durch geeignete Filterung der Messerwerte eine verbesserte, aber immer noch fehlerbehaftete, Schätzung für die Position bestimmen. [1]

5. Zusammenfassung und Ausblick

Mithilfe der Sensoren eines Trägheitsnavigationssystems lassen sich die aktuelle Beschleunigung und Drehrate bestimmen. Darüber lassen sich fehlerbehaftete Positions- und Orientierungsdaten berechnen. Trotz Messabweichungen kann gesagt werden, dass inertielle Navigationssysteme für die Positionsbestimmung geeignet sind. Ohne vorherige Filterung sind die gemessenen Werte aber zu ungenau. Deshalb muss jede Art der Messabweichungen einzeln betrachtet und behandelt werden. Durch geeignete Filterung können diese Fehler minimiert werden. Die Genauigkeit durch die Filterung kann durch Stützungsmöglichkeiten weiter verbessert werden. Je mehr Stützungsmöglichkeiten verwendet werden, desto mehr Informationen werden geliefert, was die Schätzung der Position genauer macht. Wie stark die Positionsbestimmung durch einen Filter verbessert werden kann ist bei jedem Filter unterschiedlich. Dabei kann der Kalman-Filter nur auf lineare Probleme angewendet werden. Außerdem ist die Schätzung mit dem Kalman-Filter nur optimal, wenn die Messabweichungen normalverteilt sind. Der Partikel-Filter hingegen kann auch auf nichtlineare Probleme angewandt werden. Seine Genauigkeit und Konvergenzgeschwindigkeit können verbessert werden, indem die Anzahl der Partikel für die Schätzung erhöht wird. Im Rahmen der Bachelorarbeit werden die Auswirkungen von Vibrationen auf ein Trägheitsnavigationssystem analysiert, welche an einem geeigneten Prüfstand gemessen werden. Außerdem werden sowohl der Kalman- als auch Partikel-Filter implementiert und deren Grad der Verbesserung für die Positionsbestimmung untersucht.

Literaturverzeichnis

- [1] Markus Haid „Verbesserung der referenzlosen inertialen Objektverfolgung zur Low-cost Indoor-Navigation durch Anwendung der Kalman-Filterung“, Fraunhofer IRB Verlag, 2005
- [2] GeneSys Elektronik GmbH, Beschreibung inertialer Sensoren und Systeme, 2001
Online: 13.12.2011
http://www.genesys-offenburg.de/pdfs/inert_dt.pdf
- [3] Josef Kolerus, Johann Wassermann „Zustandsüberwachung von Maschinen“ 5. Neubearbeitete Auflage, expert Verlag, 2011
- [4] Accessscience, Online: 13.12.2011 <http://accessscience.com/loadBinary.aspx?alD=5753&filename=342700FG0040.gif>
- [5] Jean-Marie Zogg „GPS und GNSS: Grundlagen der Ortung und Navigation mit Satelliten“, ublox, aktualisiert: Oktober 2011
- [6] Stuart Russell, Peter Norvig „Künstliche Intelligenz, ein moderner Ansatz“ 2. Auflage, Pearson Studium, 2004
- [7] Sebastian Thrun, Wolfram Burgard, Dieter Fox „Probabilistic Robotics“, The MIT Press, 2006
- [8] Rudolf E. Kálmán „A new Approach to Linear Filtering and Prediction Problems“, ASME, 1960

Abbildungsverzeichnis

Abbildung 1: Anordnung der Sensoren in einem inertialen Navigationssystem	2
Abbildung 2: Einfluss der Abweichungen auf die Beschleunigung	5
Abbildung 3: Drift mit linearer Abweichung.....	6
Abbildung 4: Drift mit quadratischer Abweichung.....	6
Abbildung 5: Typische Anwendung eines Filteralgorithmus	8
Abbildung 6: Wahrscheinlichkeitsdichte der Position einer bewegenden Person	10
Abbildung 7: Gaußsche Verteilungen eines eindimensionalen Beispiels	16
Abbildung 8: Ablauf eines Partikel-Filters	18
Abbildung 9: Verteilung der Partikel für die Roboterposition	19

Formelverzeichnis

Formel 1: Erste Herleitung aus dem zweiten Gesetz der Mechanik von Newton	3
Formel 2: Zweite Herleitung aus dem zweiten Gesetz der Mechanik von Newton	3
Formel 3: Aufsummierung der Differenz von Messwerten und realen Werten.....	4
Formel 4: Übergangsmodell für Prozesse erster Stufe	9
Formel 5: Sensormodell für Prozesse erster Stufe	9
Formel 6: Einstufige vorhergesagte Verteilung	11
Formel 7: Aktualisierung der Verteilung	11
Formel 8: Beispiel einer unbedingten Gaußschen Verteilung	12
Formel 9: Eindimensionale unbedingte Anfangsverteilung.....	12
Formel 10: Eindimensionales Übergangsmodell mit Gaußschem Rauschen.....	12
Formel 11: Eindimensionales Sensormodell mit Gaußschem Rauschen	12
Formel 12: Eindimensionale einstufige vorhergesagte Verteilung.....	13
Formel 13: Vereinfachte eindimensionale einstufige vorhergesagte Verteilung	13
Formel 14: Aktualisierte eindimensionale einstufige vorhergesagte Verteilung	13
Formel 15: Vereinfachte aktualisierte eindimensionale einstufige vorhergesagte Verteilung	14
Formel 16: Berechnung des neuen Mittelwertes	14
Formel 17: Berechnung der neuen Varianz	14
Formel 18: Allgemeine multivariate Gaußsche Verteilung.....	15
Formel 19: Allgemeines Übergangsmodell mit Gaußschem Rauschen	15
Formel 20: Allgemeines Sensormodell mit Gaußschem Rauschen.....	15
Formel 21: Allgemeine Aktualisierung der Mittelwertmatrix.....	15
Formel 22: Allgemeine Aktualisierung der Kovarianzmatrix	15
Formel 23: Definition der Kalman-Gewinnmatrix.....	16
Formel 24: Aufsummierung aller Gewichtungen	17

Formel 25: Anfangswerte der Gewichtungen jedes Partikels.....	18
Formel 26: Normalisierung der Gewichtungen	19

Abkürzungsverzeichnis

INS	Inertiales Navigationssystem
MEMS	Mikroelektromechanische Systeme
GPS	Global Positioning System
SPS	Standard Positioning Service
PPS	Precise Positioning Service

Einheitenverzeichnis

Beschleunigung	a	Meter pro Sekunde ² (m/s^2)
Geschwindigkeit	v	Meter pro Sekunde (m/s)
Positionsänderung	s	Meter (m)
Zeit	t	Sekunden (s)
Winkelgeschwindigkeit	ω	Grad pro Sekunde ($^\circ/s$)

Anhang

Motion Tracker Test & Calibration Certificate



Type name: MTI-G
 Product ID: MTI-G-28A53G35
 Device ID: 01500286
 Tested on: 13-May-2011
 Calibrated on: 13-May-2011

[Signature]
 Test Engineer Signature

IMU Specifications	Accelerometer	Rate Gyro	Magnetometer
Full Scale:	50 [m/s ²]	300 [deg/s]	5 [a.u.]
Bandwidth [Hz]:	30	40	10
Default Sample Frequency [Hz]:	100		
Default Baudrate [bps]:	115200		

Basic test results	Accelerometer	Rate Gyro	Magnetometer
Noise:	0.008 [m/s ²]	0.005 [rad/s]	0.002 [a.u.]
Static accuracy residual:	0.505 [deg]	Temperature residual:	0.231 [deg]
	Barometer	GPS	
Noise:	6.819 [Pa]	Single Sat. SNR > 47 dB:	OK

Calibration Data

Please refer to Technical Documentation for interpretation of values!

Accelerometer	Gains			Offsets		
	415	413	417	33141	33228	32448
	Alignment Matrix			Temperature Parameters		
	1.00	0.01	0.00	a	b	
	-0.01	1.00	0.00	0.041	0.009	
	-0.04	-0.03	1.00			
Rate Gyro	Gains			Offsets		
	4557	4479	4690	32328	32447	31250
	Alignment Matrix			Temperature Parameters		
	1.00	0.00	0.04	a	b	
	-0.01	1.00	-0.02	n/a	0.146	
	0.00	0.01	1.00			
Magnetometer	Gains			Offsets		
	7651	7278	7665	32765	33711	31912
	Alignment Matrix			Temperature Parameters		
	1.00	0.00	0.01	a	b	
	0.01	1.00	-0.02	0.360	0.000	
	0.01	0.01	1.00			

Xsens Technologies B.V.

Pantheon 6a
 P.O. Box 559
 7500 AN Enschede
 The Netherlands

phone +31-(0)88-9736700
 fax +31-(0)88-9736701
 internet www.xsens.com
 support www.xsens.com/support

Anhang 1: MTI-G Spezifikationen